TALLER FINAL DE MINERÍA DE DATOS

Segmentación de clientes con K-Means

Profesor: ORDONEZ QUINTERO, CRISTIAN CAMILO

Estudiante: Dania Kathalina Urbina Portilla

Este trabajo desarrolla un proceso de segmentación de clientes con el dataset Mall Customers. Se exploran los datos, se escalan las variables, se comparan distintos valores de K y se interpretan los grupos obtenidos para proponer estrategias de marketing.

Resultado principal: se selecciona K=5. El coeficiente de silueta máximo evaluado es 0.555, también en K=5.

1. Exploración y preprocesamiento

El archivo contiene 200 registros y 5 variables: CustomerID, Gender, Age, Annual Income (k$) y Spending Score (1-100). No se encontraron valores faltantes ni filas duplicadas. La edad promedio es 38.85 años; el ingreso anual promedio es 60.56 k$; y la puntuación de gasto promedio es 50.20.

Se seleccionaron ingreso anual y puntuación de gasto para entrenar K-Means. CustomerID se excluye porque es un identificador; Gender se reserva para descripción y Age se utiliza como variable complementaria para caracterizar los grupos. La correlación lineal entre ingreso y puntuación de gasto es aproximadamente 0,01, por lo que no hay una relación lineal global importante entre ambas variables.

Valores atípicos

Con el criterio IQR se detectan dos observaciones de ingreso anual de 137 k$ por encima del límite superior. Se conservan porque el archivo no aporta evidencia de que sean errores. No se detectan valores atípicos por IQR en edad ni en puntuación de gasto.

¿Por qué escalar?

K-Means usa distancias euclidianas; StandardScaler centra cada variable y la divide por su desviación estándar. Esto evita que una variable domine la distancia solo por su escala y permite comparar ingreso y puntuación de gasto.

2. Selección del número de clusters

Se evaluaron valores de K entre 1 y 10 para el método del codo y entre 2 y 10 para el coeficiente de silueta. La inercia mide la suma de las distancias cuadráticas entre los puntos y sus centroides: disminuye al añadir clusters, así que no debe usarse de forma aislada.

K	Inercia	Silueta
2	269.691	0.3213
3	157.704	0.4666
4	108.921	0.4939
5	65.568	0.5547
6	55.057	0.5399
7	44.865	0.5281
8	37.228	0.4552
9	32.392	0.4571
10	29.982	0.4432

La silueta máxima fue 0.5547 con K=5. El método del codo también respalda K=5, ya que después de ese punto la disminución de la inercia se vuelve menos pronunciada. Por ello, se selecciona K=5 como un equilibrio entre compacidad, separación e interpretabilidad.

3. Modelo final e interpretación de clusters

El modelo final utiliza StandardScaler y KMeans con K=5, random_state=42 y n_init=10. Los centroides se muestran en las unidades originales para facilitar su interpretación.

Cluster	Clientes	Edad media	Ingreso medio (k$)	Gasto medio	Perfil
0	81	42.7	55.3	49.5	Clientes promedio
1	39	32.7	86.5	82.1	Clientes de alto valor
2	22	25.3	25.7	79.4	Alto gasto con ingreso limitado
3	35	41.1	88.2	17.1	Clientes con potencial
4	23	45.2	26.3	20.9	Clientes de bajo valor actual

Los identificadores 0 a 4 son etiquetas técnicas del algoritmo y no constituyen un ranking. Los centroides representan el ingreso y la puntuación de gasto promedio del grupo en las unidades originales.

4. Interpretación de negocio y despliegue

Perfil	Características	Estrategia sugerida
Alto valor	Ingreso alto y gasto alto	Beneficios VIP, recompensas, preventas y atención personalizada.
Promedio	Ingreso y gasto intermedios	Venta cruzada, recomendaciones complementarias y retención.
Bajo valor actual	Ingreso bajo y gasto bajo	Opciones económicas y promociones controladas.
Con potencial	Ingreso alto y gasto bajo	Investigar barreras de compra y probar ofertas personalizadas.
Gasto alto con ingreso limitado	Ingreso bajo y gasto alto	Fidelización accesible y paquetes con precio claro.

Mayor oportunidad de crecimiento

El cluster 3 presenta un ingreso promedio cercano a 88,2 k$ y una puntuación de gasto promedio de 17,1. Puede ser un segmento de crecimiento porque combina ingreso relativamente alto con bajo gasto registrado. Se recomienda validar las barreras de compra mediante encuestas y pruebas de marketing, sin asumir que la puntuación por sí sola demuestra intención futura.

Despliegue con Streamlit

El archivo app.py permite visualizar el método del codo y la silueta, cambiar K, observar los clusters y sus centroides, introducir un nuevo cliente y clasificarlo automáticamente. Para ejecutarlo, instalar las dependencias indicadas en requirements.txt y correr `streamlit run app.py` desde la carpeta del proyecto.

Conclusiones y limitaciones

K=5 ofrece un equilibrio razonable entre ajuste e interpretación. Los segmentos permiten diseñar estrategias distintas según ingreso y puntuación de gasto. Sin embargo, el dataset no contiene historial transaccional, margen, frecuencia de compra ni respuesta a campañas; por tanto, los perfiles son descriptivos y deben validarse con datos comerciales adicionales antes de tomar decisiones reales.